

✓ **PREDICCIÓN DEL TRASTORNO DEL ESPECTRO AUTISMO- TEA**

El trastorno del espectro autista es una afección relacionada con el desarrollo del cerebro que afecta la manera en la que una persona percibe y socializa con otras personas, lo que causa problemas en la interacción social y la comunicación. El trastorno también comprende patrones de conducta restringidos y repetitivos. El término «espectro» en el trastorno del espectro autista se refiere a un amplio abanico de síntomas y gravedad.

Ref : <https://www.mayoclinic.org/es/diseases-conditions/autism-spectrum-disorder/symptoms-causes/syc-20352928>

Cuaderno Desarrollado por :

RUBEN DARIO SABOGAL URBANO



✓ CONJUNTO DE DATOS

El conjunto de Datos , proviene de: <https://www.kaggle.com/datasets/andrewmvd/autism-screening-on-adults>

<https://archive.ics.uci.edu/dataset/426/autism+screening+adult>

para los cuales se procede a hacer su tratamiento, la cual es la Lista de verificación Modificada para el autismo en niños pequeños, revisada M-CHAT-R.

El principal test de cribado para la detección temprana del autismo en niños pequeños es la **Lista de Verificación Modificada para el Autismo en Niños Pequeños, Revisada (M-CHAT-R)**, un **cuestionario de 20 preguntas** que los padres o cuidadores completan para identificar posibles señales de autismo. Para adultos y niños mayores, existen otras herramientas como el Autism Quotient (AQ) o la Escala de Diagnóstico de Autismo y Asperger de Ritvo (RAADS-14)>>, que evalúan habilidades de lenguaje, interacción social e intereses.

M-CHAT-R

La lista de verificación modificada para autismo en niños pequeños, revisada (M-CHAT-R) es una evaluación que hace una serie de 20 preguntas sobre el comportamiento de su hijo/a. Es administrado para niños pequeños entre 16 y 30 meses de edad. Los resultados le permitirán saber si es necesario una evaluación adicional.

Por favor responda a estas preguntas sobre su hijo/a. Tenga en cuenta **cómo su hijo/a se comporta habitualmente**. Si usted ha visto a su hijo/a comportarse de una de estas maneras algunas veces, pero no es un comportamiento habitual, por favor responda **no**. Seleccione, rodeando con un círculo, Muchas gracias.

1. Si usted señala algo al otro lado de la habitación, ¿su hijo/a lo mira? (POR EJEMPLO, Si usted señala a un juguete, un peluche o un animal, ¿su hijo/a lo mira?)	SÍ	NO
2. ¿Alguna vez se ha preguntado si su hijo/a es sordo/a?	SÍ	NO
3. ¿Su hijo/a juega juegos de fantasía o imaginación? (POR EJEMPLO, “hace como que” bebe de una taza vacía, habla por teléfono o da de comer a una muñeca o peluche,...)	SÍ	NO
4. ¿A su hijo le gusta subirse a cosas? (POR EJEMPLO, a una silla, escaleras, o tobogán,...)	SÍ	NO
5. ¿Hace su hijo/a movimientos inusuales con sus dedos cerca de sus ojos? (POR EJEMPLO, mueve sus dedos cerca de sus ojos de manera inusual?)	SÍ	NO
6. ¿Su hijo/a señala con un dedo cuando quiere pedir algo o pedir ayuda? (POR EJEMPLO, señala un juguete o algo de comer que está fuera de su alcance?)	SÍ	NO
7. Su hijo/a señala con un dedo cuando quiere mostrarle algo que le llama la atención? (POR EJEMPLO, señala un avión en el cielo o un camión muy grande en la calle)	SÍ	NO
8. ¿Su hijo/a se interesa en otros niños? (POR EJEMPLO, mira con atención a otros niños, les sonríe o se les acerca?)	SÍ	NO
9. ¿Su hijo/a le muestra cosas acercándolas o levantándolas para que usted las vea – no para pedir ayuda sino solamente para compartirlas con usted? (POR EJEMPLO, le muestra una flor o un peluche o un coche de juguete)	SÍ	NO
10. ¿Su hijo/a responde cuando usted le llama por su nombre? (POR EJEMPLO, se vuelve, habla o balbucea, o deja de hacer lo que estaba haciendo para mirarle?)	SÍ	NO
11. ¿Cuándo usted sonríe a su hijo/a, él o ella también le sonríe?	SÍ	NO
12. ¿Le molestan a su hijo/a ruidos cotidianos? (POR EJEMPLO, la aspiradora o la música, incluso cuando está no está excesivamente alta?)	SÍ	NO
13. ¿Su hijo/a camina solo?	SÍ	NO
14. ¿Su hijo/a le mira a los ojos cuando usted le habla, juega con él o ella, o lo viste?	SÍ	NO
15. ¿Su hijo/a imita sus movimientos? (POR EJEMPLO, decir adiós con la mano, aplaudir o algún ruido gracioso que usted haga?)	SÍ	NO
16. Si usted se gira a ver algo, ¿su hijo/a trata de mirar hacia lo que usted está mirando?	SÍ	NO
17. ¿Su hijo/a intenta que usted le mire/preste atención? (POR EJEMPLO, busca que usted le haga un cumplido, o le dice “mira” ó “mírame”)	SÍ	NO
18. ¿Su hijo/a le entiende cuando usted le dice que haga algo? (POR EJEMPLO, si usted no hace gestos, ¿su hijo/a entiende “pon el libro encima de la silla” o “tráeme la manta”?)	SÍ	NO
19. Si algo nuevo pasa, ¿su hijo/a le mira para ver como usted reacciona al respecto? (POR EJEMPLO, si oye un ruido extraño o ve un juguete nuevo, ¿se gira a ver su cara?)	SÍ	NO
20. Le gustan a su hijo/a los juegos de movimiento? (POR EJEMPLO, le gusta que le balancee, o que le haga “el caballito” sentándole en sus rodillas)	SÍ	NO

Análisis Exploratorio de Datos para la Predicción del Trastorno del Espectro Autista (TEA) Basado en los documentos proporcionados, voy a desarrollar un análisis exploratorio de datos completo para la predicción del TEA, siguiendo los requisitos solicitados.

1. Análisis Univariado en Python El análisis univariado examina cada variable por separado para entender su distribución, patrones y posibles problemas. Aquí está el código implementado para el análisis univariado:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

# Configuración de visualización
plt.style.use('seaborn-v0_8-whitegrid')
sns.set_palette("pastel")
plt.rcParams['figure.figsize'] = (14, 10)
plt.rcParams['font.size'] = 12

# Cargar el dataset
df = pd.read_csv('autism_screening.csv', na_values='?')

# 1. Información general del dataset
print("="*70)
print("INFORMACIÓN GENERAL DEL DATASET")
print("="*70)
print(f"Forma del dataset: {df.shape}")
print(f"Número de variables: {df.shape[1]}")
print(f"Número de observaciones: {df.shape[0]}")
print("\nTipos de datos por variable:")
print(df.dtypes.value_counts())
print("\nInformación detallada del dataset:")
print(df.info())
print("\nPrimeras 5 filas del dataset:")
print(df.head())

# 2. Análisis univariado para variables numéricas
print("\n" + "="*70)
print("ANÁLISIS UNIVARIADO DE VARIABLES NUMÉRICAS")
print("="*70)

# Identificar variables numéricas
numeric_cols = df.select_dtypes(include=['int64', 'float64']).columns.tolist()
print(f"\nVariables numéricas identificadas ({len(numeric_cols)}): {numeric_cols}")

# Función para análisis univariado de variables numéricas
def univariate_numeric_analysis(column):
    print(f"\n--- Análisis de {column} ---")
```

```

# Estadísticas descriptivas
print("\nEstadísticas descriptivas:")
print(f"Media: {df[column].mean():.4f}")
print(f"Mediana: {df[column].median():.4f}")
print(f"Moda: {df[column].mode().iloc[0] if not df[column].mode().empty else 'N/A'}")
print(f"Desviación estándar: {df[column].std():.4f}")
print(f"Rango intercuartílico (IQR): {df[column].quantile(0.75) - df[column].quantile(0.25):.4f}")
print(f"Valor mínimo: {df[column].min():.4f}")
print(f"Valor máximo: {df[column].max():.4f}")
print(f"Rango: {df[column].max() - df[column].min():.4f}")
print(f"Coeficiente de asimetría: {df[column].skew():.4f}")
print(f"Coeficiente de curtosis: {df[column].kurtosis():.4f}")

# Detección de outliers usando IQR
Q1 = df[column].quantile(0.25)
Q3 = df[column].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
outliers = df[(df[column] < lower_bound) | (df[column] > upper_bound)][column]
print(f"\nNúmero de outliers detectados: {len(outliers)} ({len(outliers)/len(df)*100:.2f}%)")

# Visualización
plt.figure(figsize=(14, 10))

# Histograma con curva de densidad
plt.subplot(2, 2, 1)
sns.histplot(df[column], kde=True, color='skyblue')
plt.axvline(df[column].mean(), color='r', linestyle='--', label='Media')
plt.axvline(df[column].median(), color='g', linestyle='--', label='Mediana')
plt.title(f'Distribución de {column}')
plt.xlabel(column)
plt.ylabel('Frecuencia')
plt.legend()

# Boxplot
plt.subplot(2, 2, 2)
sns.boxplot(x=df[column], color='lightgreen')
plt.title(f'Boxplot de {column}')
plt.xlabel(column)

# Q-Q plot para verificar normalidad
plt.subplot(2, 2, 3)
stats.probplot(df[column].dropna(), dist="norm", plot=plt)
plt.title(f'Q-Q Plot de {column}')

# Gráfico de densidad
plt.subplot(2, 2, 4)
sns.kdeplot(df[column], color='purple', fill=True)
plt.title(f'Curva de Densidad de {column}')

```

```

plt.xlabel(column)
plt.ylabel('Densidad')

plt.tight_layout()
plt.savefig(f'distribucion_{column}.png', dpi=300, bbox_inches='tight')
print(f"✓ Visualización de {column} generada: 'distribucion_{column}.png'")

# Aplicar análisis a todas las variables numéricas
for col in numeric_cols:
    univariate_numeric_analysis(col)

# 3. Análisis univariado para variables categóricas
print("\n" + "="*70)
print("ANÁLISIS UNIVARIADO DE VARIABLES CATEGÓRICAS")
print("="*70)

# Identificar variables categóricas
categorical_cols = df.select_dtypes(include=['object']).columns.tolist()
print(f"\nVariables categóricas identificadas ({len(categorical_cols)}): {categorical_cols}'

# Función para análisis univariado de variables categóricas
def univariate_categorical_analysis(column):
    print(f"\n--- Análisis de {column} ---")

    # Estadísticas descriptivas
    print("\nConteo de categorías:")
    print(df[column].value_counts())

    print("\nPorcentaje por categoría:")
    print(df[column].value_counts(normalize=True) * 100)

    print(f"\nNúmero de categorías únicas: {df[column].nunique()}")
    print(f"Moda: {df[column].mode().iloc[0] if not df[column].mode().empty else 'N/A'}")

    # Visualización
    plt.figure(figsize=(14, 6))

    # Gráfico de barras
    plt.subplot(1, 2, 1)
    ax = sns.countplot(x=df[column], order=df[column].value_counts().index)
    plt.title(f'Distribución de {column}')
    plt.xlabel(column)
    plt.ylabel('Frecuencia')
    plt.xticks(rotation=45)

    # Añadir porcentajes en las barras
    for p in ax.patches:
        height = p.get_height()
        ax.annotate(f'{height/len(df)*100:.1f}%',
                    (p.get_x() + p.get_width()/2., height),
                    ha='center', va='center',

```

```
xytext=(0, 5),  
textcoords='offset points')
```

```
# Gráfico de pastel  
plt.subplot(1, 2, 2)  
counts = df[column].value_counts()  
plt.pie(counts, labels=counts.index, autopct='%1.1f%%', startangle=90)  
plt.title(f'Proporción de {column}')  
plt.axis('equal')  
  
plt.tight_layout()  
plt.savefig(f'distribucion_{column}.png', dpi=300, bbox_inches='tight')  
print(f"✓ Visualización de {column} generada: 'distribucion_{column}.png'")
```

```
# Aplicar análisis a todas las variables categóricas  
for col in categorical_cols:  
    if col != 'Class/ASD': # Exclude the target variable from the categorical analysis if it  
        univariate_categorical_analysis(col)
```



```
=====
INFORMACIÓN GENERAL DEL DATASET
=====
Forma del dataset: (704, 21)
Número de variables: 21
Número de observaciones: 704

Tipos de datos por variable:
int64      10
object      9
float64     2
Name: count, dtype: int64

Información detallada del dataset:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 704 entries, 0 to 703
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   A1_Score              704 non-null   int64
1   A2_Score              704 non-null   int64
2   A3_Score              704 non-null   int64
3   A4_Score              704 non-null   int64
4   A5_Score              704 non-null   int64
5   A6_Score              704 non-null   int64
6   A7_Score              704 non-null   int64
7   A8_Score              704 non-null   int64
8   A9_Score              704 non-null   int64
9   A10_Score             704 non-null   int64
10  age                   702 non-null   float64
11  gender                704 non-null   object
12  ethnicity             609 non-null   object
13  jundice               704 non-null   object
14  austim                704 non-null   object
15  contry_of_res         704 non-null   object
16  used_app_before       704 non-null   object
17  result                704 non-null   float64
18  age_desc              704 non-null   object
19  relation              609 non-null   object
20  Class/ASD             704 non-null   object
dtypes: float64(2), int64(10), object(9)
memory usage: 115.6+ KB
None
```

Primeras 5 filas del dataset:

	A1_Score	A2_Score	A3_Score	A4_Score	A5_Score	A6_Score	A7_Score	\
0	1	1	1	1	0	0	1	
1	1	1	0	1	0	0	0	
2	1	1	0	1	1	0	1	
3	1	1	0	1	0	0	1	
4	1	0	0	0	0	0	0	

	A8_Score	A9_Score	A10_Score	...	gender	ethnicity	jundice	austim	\
0	1	0	0	...	f	White-European	no	no	
1	1	0	1	...	m	Latino	no	yes	
2	1	1	1	...	m	Latino	yes	yes	

3	1	0	1	...	f	White-European	no	yes
4	1	0	0	...	f	NaN	no	no

	contry_of_res	used_app_before	result	age_desc	relation	Class/ASD
0	United States		no	6.0	18 and more	Self NO
1	Brazil		no	5.0	18 and more	Self NO
2	Spain		no	8.0	18 and more	Parent YES
3	United States		no	6.0	18 and more	Self NO
4	Egypt		no	2.0	18 and more	NaN NO

[5 rows x 21 columns]

ANÁLISIS UNIVARIADO DE VARIABLES NUMÉRICAS

Variables numéricas identificadas (12): ['A1_Score', 'A2_Score', 'A3_Score', 'A4_Score

--- Análisis de A1_Score ---

Estadísticas descriptivas:

Media: 0.7216

Mediana: 1.0000

Moda: 1

Desviación estándar: 0.4485

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000

Coefficiente de asimetría: -0.9909

Coefficiente de curtosis: -1.0211

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de A1_Score generada: 'distribucion_A1_Score.png'

--- Análisis de A2_Score ---

Estadísticas descriptivas:

Media: 0.4531

Mediana: 0.0000

Moda: 0

Desviación estándar: 0.4982

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000

Coefficiente de asimetría: 0.1887

Coefficiente de curtosis: -1.9700

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de A2_Score generada: 'distribucion_A2_Score.png'

--- Análisis de A3_Score ---

Estadísticas descriptivas:

Media: 0.4574

Mediana: 0.0000

Media: 0.4985

Moda: 0

Desviación estándar: 0.4985

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000

Coeficiente de asimetría: 0.1714

Coeficiente de curtosis: -1.9762

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de A3_Score generada: 'distribucion_A3_Score.png'

--- Análisis de A4_Score ---

Estadísticas descriptivas:

Media: 0.4957

Mediana: 0.0000

Moda: 0

Desviación estándar: 0.5003

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000

Coeficiente de asimetría: 0.0171

Coeficiente de curtosis: -2.0054

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de A4_Score generada: 'distribucion_A4_Score.png'

--- Análisis de A5_Score ---

Estadísticas descriptivas:

Media: 0.4986

Mediana: 0.0000

Moda: 0

Desviación estándar: 0.5004

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000

Coeficiente de asimetría: 0.0057

Coeficiente de curtosis: -2.0057

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de A5_Score generada: 'distribucion_A5_Score.png'

--- Análisis de A6_Score ---

Estadísticas descriptivas:

Media: 0.2841

Mediana: 0.0000

Moda: 0

Desviación estándar: 0.4513

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000
Coeficiente de asimetría: 0.9596
Coeficiente de curtosis: -1.0823

Número de outliers detectados: 0 (0.00% del total)
✓ Visualización de A6_Score generada: 'distribucion_A6_Score.png'

--- Análisis de A7_Score ---

Estadísticas descriptivas:
Media: 0.4176
Mediana: 0.0000
Moda: 0
Desviación estándar: 0.4935
Rango intercuartílico (IQR): 1.0000
Valor mínimo: 0.0000
Valor máximo: 1.0000
Rango: 1.0000
Coeficiente de asimetría: 0.3348
Coeficiente de curtosis: -1.8933

Número de outliers detectados: 0 (0.00% del total)
✓ Visualización de A7_Score generada: 'distribucion_A7_Score.png'

--- Análisis de A8_Score ---

Estadísticas descriptivas:
Media: 0.6491
Mediana: 1.0000
Moda: 1
Desviación estándar: 0.4776
Rango intercuartílico (IQR): 1.0000
Valor mínimo: 0.0000
Valor máximo: 1.0000
Rango: 1.0000
Coeficiente de asimetría: -0.6264
Coeficiente de curtosis: -1.6122

Número de outliers detectados: 0 (0.00% del total)
✓ Visualización de A8_Score generada: 'distribucion_A8_Score.png'

--- Análisis de A9_Score ---

Estadísticas descriptivas:
Media: 0.3239
Mediana: 0.0000
Moda: 0
Desviación estándar: 0.4683
Rango intercuartílico (IQR): 1.0000
Valor mínimo: 0.0000
Valor máximo: 1.0000
Rango: 1.0000
Coeficiente de asimetría: 0.7544
Coeficiente de curtosis: -1.4349

Número de outliers detectados: 0 (0.00% del total)
✓ Visualización de A9_Score generada: 'distribucion_A9_Score.png'

✓ Visualización de A10_Score generada: 'distribucion_A10_Score.png'

--- Análisis de A10_Score ---

Estadísticas descriptivas:

Media: 0.5739

Mediana: 1.0000

Moda: 1

Desviación estándar: 0.4949

Rango intercuartílico (IQR): 1.0000

Valor mínimo: 0.0000

Valor máximo: 1.0000

Rango: 1.0000

Coeficiente de asimetría: -0.2994

Coeficiente de curtosis: -1.9158

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de A10_Score generada: 'distribucion_A10_Score.png'

--- Análisis de age ---

Estadísticas descriptivas:

Media: 29.6980

Mediana: 27.0000

Moda: 21.0

Desviación estándar: 16.5075

Rango intercuartílico (IQR): 14.0000

Valor mínimo: 17.0000

Valor máximo: 383.0000

Rango: 366.0000

Coeficiente de asimetría: 14.2042

Coeficiente de curtosis: 299.2847

Número de outliers detectados: 8 (1.14% del total)

✓ Visualización de age generada: 'distribucion_age.png'

--- Análisis de result ---

Estadísticas descriptivas:

Media: 4.8750

Mediana: 4.0000

Moda: 4.0

Desviación estándar: 2.5015

Rango intercuartílico (IQR): 4.0000

Valor mínimo: 0.0000

Valor máximo: 10.0000

Rango: 10.0000

Coeficiente de asimetría: 0.3234

Coeficiente de curtosis: -0.7168

Número de outliers detectados: 0 (0.00% del total)

✓ Visualización de result generada: 'distribucion_result.png'

=====

ANÁLISIS UNIVARIADO DE VARIABLES CATEGÓRICAS

=====

Variables categóricas identificadas (9): ['gender', 'ethnicity', 'jundice', 'austim',

--- Análisis de gender ---

Conteo de categorías:

gender

m 367

f 337

Name: count, dtype: int64

Porcentaje por categoría:

gender

m 52.130682

f 47.869318

Name: proportion, dtype: float64

Número de categorías únicas: 2

Moda: m

✓ Visualización de gender generada: 'distribucion_gender.png'

--- Análisis de ethnicity ---

Conteo de categorías:

ethnicity

White-European 233

Asian 123

Middle Eastern 92

Black 43

South Asian 36

Others 30

Latino 20

Hispanic 13

Pasifika 12

Turkish 6

others 1

Name: count, dtype: int64

Porcentaje por categoría:

ethnicity

White-European 38.259442

Asian 20.197044

Middle Eastern 15.106732

Black 7.060755

South Asian 5.911330

Others 4.926108

Latino 3.284072

Hispanic 2.134647

Pasifika 1.970443

Turkish 0.985222

others 0.164204

Name: proportion, dtype: float64

Número de categorías únicas: 11

Moda: White-European

✓ Visualización de ethnicity generada: 'distribucion_ethnicity.png'

--- Análisis de iundice ---

----- de jundice

Conteo de categorías:

jundice

no 635

yes 69

Name: count, dtype: int64

Porcentaje por categoría:

jundice

no 90.198864

yes 9.801136

Name: proportion, dtype: float64

Número de categorías únicas: 2

Moda: no

✓ Visualización de jundice generada: 'distribucion_jundice.png'

--- Análisis de austim ---

Conteo de categorías:

austim

no 613

yes 91

Name: count, dtype: int64

Porcentaje por categoría:

austim

no 87.073864

yes 12.926136

Name: proportion, dtype: float64

Número de categorías únicas: 2

Moda: no

✓ Visualización de austim generada: 'distribucion_austim.png'

--- Análisis de contry_of_res ---

Conteo de categorías:

contry_of_res

United States 113

United Arab Emirates 82

New Zealand 81

India 81

United Kingdom 77

...

Angola 1

Azerbaijan 1

Iraq 1

Czech Republic 1

Cyprus 1

Name: count, Length: 67, dtype: int64

Porcentaje por categoría:

contry_of_res

United States 16.051136

United Arab Emirates 11.647727

```
New Zealand      11.505682
India            11.505682
United Kingdom   10.937500
...
Angola           0.142045
Azerbaijan       0.142045
Iraq             0.142045
Czech Republic   0.142045
Cyprus            0.142045
Name: proportion, Length: 67, dtype: float64
```

Número de categorías únicas: 67

Moda: United States

✓ Visualización de contry_of_res generada: 'distribucion_contry_of_res.png'

--- Análisis de used_app_before ---

Conteo de categorías:

used_app_before

no 692

yes 12

Name: count, dtype: int64

Porcentaje por categoría:

used_app_before

no 98.295455

yes 1.704545

Name: proportion, dtype: float64

Número de categorías únicas: 2

Moda: no

✓ Visualización de used_app_before generada: 'distribucion_used_app_before.png'

--- Análisis de age_desc ---

Conteo de categorías:

age_desc

18 and more 704

Name: count, dtype: int64

Porcentaje por categoría:

age_desc

18 and more 100.0

Name: proportion, dtype: float64

Número de categorías únicas: 1

Moda: 18 and more

✓ Visualización de age_desc generada: 'distribucion_age_desc.png'

--- Análisis de relation ---

Conteo de categorías:

relation

Self 522

Parent 50


Relative 28











Others 5










Health care professional 4
Name: count, dtype: int64











Porcentaje por categoría:
relation
Self 85.714286
Parent 8.210181
Relative 4.597701
Others 0.821018
Health care professional 0.656814
Name: proportion, dtype: float64











Número de categorías únicas: 5
Moda: Self
✓ Visualización de relation generada: 'distribucion_relation.png'















































Este código realiza un análisis univariado completo de todas las variables en el dataset, generando:

Estadísticas descriptivas para variables numéricas (media, mediana, moda, desviación estándar, etc.) Detección de outliers usando el método IQR Visualizaciones completas (histogramas, boxplots, Q-Q plots, curvas de densidad) Análisis de frecuencia y porcentaje para variables categóricas Visualizaciones de barras y gráficos de pastel

2. Análisis Bivariado El análisis bivariado examina las relaciones entre pares de variables, especialmente entre las variables predictoras y la variable objetivo (Class/ASD):

```
print("\n" + "="*70)
print("ANÁLISIS BIVARIADO")
print("="*70)

# Variable objetivo
target = 'Class/ASD'
print(f"Variable objetivo identificada: {target}")

# 1. Relación entre variables numéricas y la variable objetivo
print("\n" + "-"*50)
print("RELACIÓN ENTRE VARIABLES NUMÉRICAS Y LA VARIABLE OBJETIVO")
print("-"*50)

def bivariate_numeric_vs_target(numeric_col, target_col):
    print(f"\n--- Análisis de {numeric_col} vs {target_col} ---")

    # Tabla de resumen por clase
    print("\nEstadísticas por clase:")
    print(df.groupby(target_col)[numeric_col].describe())

    # Visualización
    plt.figure(figsize=(14, 6))

    # Boxplot por clase
    plt.subplot(1, 2, 1)
    sns.boxplot(x=target_col, y=numeric_col, data=df)
    plt.title(f'Distribución de {numeric_col} por {target_col}')
    plt.xlabel(target_col)
    plt.ylabel(numeric_col)

    # Histograma superpuesto
    plt.subplot(1, 2, 2)
    for class_value in df[target_col].unique():
        subset = df[df[target_col] == class_value]
        sns.kdeplot(subset[numeric_col], label=class_value, fill=True, alpha=0.5)
```

```

plt.title(f'Distribución de {numeric_col} por {target_col}')
plt.xlabel(numeric_col)
plt.ylabel('Densidad')
plt.legend(title=target_col)

plt.tight_layout()
plt.savefig(f'relacion_{numeric_col}_vs_{target_col.replace("/", "_")}.png', dpi=300, bt
print(f"✓ Visualización de relación generada: 'relacion_{numeric_col}_vs_{target_col.rej

# Aplicar análisis a todas las variables numéricas
for col in numeric_cols:
    if col != target:
        bivariate_numeric_vs_target(col, target)

# 2. Relación entre variables categóricas y la variable objetivo
print("\n" + "-"*50)
print("RELACIÓN ENTRE VARIABLES CATEGÓRICAS Y LA VARIABLE OBJETIVO")
print("-"*50)

def bivariate_categorical_vs_target(categorical_col, target_col):
    print(f"\n--- Análisis de {categorical_col} vs {target_col} ---")

    # Tabla de contingencia
    print("\nTabla de contingencia:")
    contingency_table = pd.crosstab(df[categorical_col], df[target_col])
    print(contingency_table)

    # Porcentajes por categoría
    print("\nPorcentajes por categoría:")
    print(pd.crosstab(df[categorical_col], df[target_col], normalize='index') * 100)

    # Visualización
    plt.figure(figsize=(14, 6))

    # Gráfico de barras apiladas
    plt.subplot(1, 2, 1)
    sns.countplot(x=categorical_col, hue=target_col, data=df)
    plt.title(f'Distribución de {categorical_col} por {target_col}')
    plt.xlabel(categorical_col)
    plt.ylabel('Frecuencia')
    plt.xticks(rotation=45)

    # Gráfico de porcentajes
    plt.subplot(1, 2, 2)
    pd.crosstab(df[categorical_col], df[target_col], normalize='index').plot(
        kind='bar', stacked=True, colormap='viridis', ax=plt.gca()
    )
    plt.title(f'Porcentaje de {target_col} por {categorical_col}')
    plt.xlabel(categorical_col)
    plt.ylabel('Porcentaje')
    plt.xticks(rotation=45)

```

```

plt.legend(title=target_col)

plt.tight_layout()
plt.savefig(f'relacion_{categorical_col}_vs_{target_col.replace("/", "_")}.png', dpi=300)
print(f"✓ Visualización de relación generada: 'relacion_{categorical_col}_vs_{target_col.replace('/', '_')}.png'")

# Aplicar análisis a todas las variables categóricas
for col in categorical_cols:
    if col != target:
        bivariate_categorical_vs_target(col, target)

# 3. Matriz de correlación para variables numéricas
print("\n" + "-"*50)
print("MATRIZ DE CORRELACIÓN")
print("-"*50)

plt.figure(figsize=(16, 12))
correlation_matrix = df[numeric_cols].corr()
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=0.5)
plt.title('Matriz de Correlación de Variables Numéricas')
plt.tight_layout()
plt.savefig('matriz_correlacion.png', dpi=300, bbox_inches='tight')
print("✓ Matriz de correlación generada: 'matriz_correlacion.png'")

# 4. Análisis de importancia por información mutua
print("\n" + "-"*50)
print("ANÁLISIS DE IMPORTANCIA POR INFORMACIÓN MUTUA")
print("-"*50)

from sklearn.preprocessing import LabelEncoder
from sklearn.feature_selection import mutual_info_classif

# Codificar la variable objetivo
le = LabelEncoder()
y = le.fit_transform(df[target])

# Prepare predictor variables
X = df.drop(columns=[target])

# Impute missing values before one-hot encoding
for col in X.columns:
    if X[col].dtype == 'object':
        X[col] = X[col].fillna(X[col].mode()[0])
    else:
        X[col] = X[col].fillna(X[col].mean())

X = pd.get_dummies(X, drop_first=True)

# Calculate mutual information
mi_scores = mutual_info_classif(X, y)

```

```
mi_scores = pd.Series(mi_scores, name="Información Mutua", index=X.columns)
mi_scores = mi_scores.sort_values(ascending=False)

# Mostrar las 15 variables más importantes
print("\nLas 15 variables con mayor información mutua:")
print(mi_scores.head(15))

# Visualizar
plt.figure(figsize=(14, 10))
mi_scores.head(15).sort_values().plot(kind='barh', color='skyblue')
plt.title('Información Mutua de las Variables con respecto a la Clase ASD')
plt.xlabel('Información Mutua')
plt.ylabel('Variables')
plt.tight_layout()
plt.savefig('informacion_mutua.png', dpi=300, bbox_inches='tight')
print("✓ Análisis de información mutua generado: 'informacion_mutua.png'")
```



```
=====
ANÁLISIS BIVARIADO
=====
```

Variable objetivo identificada: Class/ASD

```
-----
RELACIÓN ENTRE VARIABLES NUMÉRICAS Y LA VARIABLE OBJETIVO
-----
```

--- Análisis de A1_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.640777	0.480239	0.0	0.0	1.0	1.0	1.0
YES	189.0	0.941799	0.234745	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A1_Score_vs_Class_ASD.png'

--- Análisis de A2_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.359223	0.480239	0.0	0.0	0.0	1.0	1.0
YES	189.0	0.708995	0.455432	0.0	0.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A2_Score_vs_Class_ASD.png'

--- Análisis de A3_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.324272	0.468557	0.0	0.0	0.0	1.0	1.0
YES	189.0	0.820106	0.385119	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A3_Score_vs_Class_ASD.png'

--- Análisis de A4_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.353398	0.478490	0.0	0.0	0.0	1.0	1.0
YES	189.0	0.883598	0.321558	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A4_Score_vs_Class_ASD.png'

--- Análisis de A5_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.335922	0.472771	0.0	0.0	0.0	1.0	1.0
YES	189.0	0.941799	0.234745	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A5_Score_vs_Class_ASD.png'

--- Análisis de A6_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.122330	0.327985	0.0	0.0	0.0	0.0	1.0
YES	189.0	0.724868	0.447767	0.0	0.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A6_Score_vs_Class_ASD.png'

--- Análisis de A7_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.312621	0.464012	0.0	0.0	0.0	1.0	1.0
YES	189.0	0.703704	0.457836	0.0	0.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A7_Score_vs_Class_ASD.png'

--- Análisis de A8_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.580583	0.493944	0.0	0.0	1.0	1.0	1.0
YES	189.0	0.835979	0.371278	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A8_Score_vs_Class_ASD.png'

--- Análisis de A9_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.143689	0.351115	0.0	0.0	0.0	0.0	1.0
YES	189.0	0.814815	0.389479	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A9_Score_vs_Class_ASD.png'

--- Análisis de A10_Score vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	0.458252	0.498739	0.0	0.0	0.0	1.0	1.0
YES	189.0	0.888889	0.315104	0.0	1.0	1.0	1.0	1.0

✓ Visualización de relación generada: 'relacion_A10_Score_vs_Class_ASD.png'

--- Análisis de age vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	513.0	29.105263	18.18451	17.0	21.0	26.0	33.0	383.0
YES	189.0	31.306878	10.58004	17.0	22.0	30.0	38.0	61.0

✓ Visualización de relación generada: 'relacion_age_vs_Class_ASD.png'

--- Análisis de result vs Class/ASD ---

Estadísticas por clase:

	count	mean	std	min	25%	50%	75%	max
--	-------	------	-----	-----	-----	-----	-----	-----

	count	mean	std	min	25%	50%	75%	max
Class/ASD								
NO	515.0	3.631068	1.540569	0.0	3.0	4.0	5.0	6.0
YES	189.0	8.264550	1.058834	7.0	7.0	8.0	9.0	10.0

✓ Visualización de relación generada: 'relacion_result_vs_Class_ASD.png'

RELACIÓN ENTRE VARIABLES CATEGÓRICAS Y LA VARIABLE OBJETIVO

--- Análisis de gender vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
gender		
f	234	103
m	281	86

Porcentajes por categoría:

Class/ASD	NO	YES
gender		
f	69.436202	30.563798
m	76.566757	23.433243

✓ Visualización de relación generada: 'relacion_gender_vs_Class_ASD.png'

--- Análisis de ethnicity vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
ethnicity		
Asian	107	16
Black	25	18
Hispanic	8	5
Latino	10	10
Middle Eastern	84	8
Others	21	9
Pasifika	11	1
South Asian	33	3
Turkish	5	1
White-European	124	109
others	1	0

Porcentajes por categoría:

Class/ASD	NO	YES
ethnicity		
Asian	86.991870	13.008130
Black	58.139535	41.860465
Hispanic	61.538462	38.461538
Latino	50.000000	50.000000
Middle Eastern	91.304348	8.695652
Others	70.000000	30.000000
Pasifika	91.666667	8.333333
South Asian	91.666667	8.333333
Turkish	83.333333	16.666667
White-European	53.218884	46.781116
others	100.000000	0.000000

✓ Visualización de relación generada: 'relacion_ethnicity_vs_Class_ASD.png'

--- Análisis de jundice vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
jundice		
no	474	161
yes	41	28

Porcentajes por categoría:

Class/ASD	NO	YES
jundice		
no	74.645669	25.354331
yes	59.420290	40.579710

✓ Visualización de relación generada: 'relacion_jundice_vs_Class_ASD.png'

--- Análisis de austim vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
austim		
no	467	146
yes	48	43

Porcentajes por categoría:

Class/ASD	NO	YES
austim		
no	76.182708	23.817292
yes	52.747253	47.252747

✓ Visualización de relación generada: 'relacion_austim_vs_Class_ASD.png'

--- Análisis de contry_of_res vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
contry_of_res		
Afghanistan	11	2
AmericanSamoa	1	1
Angola	1	0
Argentina	1	1
Armenia	2	0
...	..	...
United Arab Emirates	79	3
United Kingdom	48	29
United States	60	53
Uruguay	0	1
Viet Nam	4	1

[67 rows x 2 columns]

Porcentajes por categoría:

Class/ASD	NO	YES
contry_of_res		
Afghanistan	84.615385	15.384615
AmericanSamoa	50.000000	50.000000
Angola	100.000000	0.000000
Argentina	50.000000	50.000000

Argentina	50.000000	50.000000
Armenia	100.000000	0.000000
...	...	...
United Arab Emirates	96.341463	3.658537
United Kingdom	62.337662	37.662338
United States	53.097345	46.902655
Uruguay	0.000000	100.000000
Viet Nam	80.000000	20.000000

[67 rows x 2 columns]

✓ Visualización de relación generada: 'relacion_contry_of_res_vs_Class_ASD.png'

--- Análisis de used_app_before vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
used_app_before		
no	508	184
yes	7	5

Porcentajes por categoría:

Class/ASD	NO	YES
used_app_before		
no	73.410405	26.589595
yes	58.333333	41.666667

✓ Visualización de relación generada: 'relacion_used_app_before_vs_Class_ASD.png'

--- Análisis de age_desc vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
age_desc		
18 and more	515	189

Porcentajes por categoría:

Class/ASD	NO	YES
age_desc		
18 and more	73.153409	26.846591

✓ Visualización de relación generada: 'relacion_age_desc_vs_Class_ASD.png'

--- Análisis de relation vs Class/ASD ---

Tabla de contingencia:

Class/ASD	NO	YES
relation		
Health care professional	3	1
Others	4	1
Parent	38	12
Relative	19	9
Self	365	157

Porcentajes por categoría:

Class/ASD	NO	YES
relation		
Health care professional	75.000000	25.000000
Others	80.000000	20.000000
Parent	76.000000	24.000000

Relative 67.857143 32.142857
Self 69.923372 30.076628
✓ Visualización de relación generada: 'relacion_relation_vs_Class_ASD.png'

MATRIZ DE CORRELACIÓN

/tmp/ipython-input-2807069663.py:104: RuntimeWarning: More than 20 figures have been opened. The current figure is not being rendered, you may want to plt.figure(figsize=(16, 12))
✓ Matriz de correlación generada: 'matriz_correlacion.png'





ANÁLISIS DE IMPORTANCIA POR INFORMACIÓN MUTUA









Las 15 variables con mayor información mutua:









result	0.582438
A9_Score	0.210293
A6_Score	0.159515
A5_Score	0.157320
A3_Score	0.104244
A4_Score	0.101292
A10_Score	0.086317
A7_Score	0.065633
A1_Score	0.063061
A8_Score	0.036550
A2_Score	0.035283
contry_of_res_Turkey	0.034127
contry_of_res_Mexico	0.032810
age	0.032695
contry_of_res_Philippines	0.031135









Name: Información Mutua, dtype: float64









✓ Análisis de información mutua generado: 'informacion_mutua.png'





















Distribución de relation por Class/ASD

Porcentaje de Class/ASD por relation

